

통계학

- 머신러닝을 위한 -

2026_Spring

조상구





- ❖ 통계는 항해사에게 등대와 같다.
- ❖ 국 한 그릇의 맛을 알기 위해 다 마셔볼 필요는 없다.
- ❖ 숫자는 스스로 말하지 않는다. 우리가 그들에게 목소리를 부여하는 것이다.
- ❖ 데이터를 충분히 고문한다면, 그것은 무엇이든 고백할 것이다.
- ❖ 통계학의 기원?

목차

1. 통계학(Statistics)
2. 모집단과 표본조사 방법
3. 데이터의 종류(Data type)
4. 주요 통계량(Statistic)
5. 다변량 분석(Multivariate Analysis)

목차

1. 통계학(Statistics)
2. 모집단과 표본조사 방법
3. 데이터의 종류(Data type)
4. 주요 통계량(Statistic)
5. 다변량 분석(Multivariate Analysis)


▪ 통계학 (Statistics) 이란?

- 자료의 수집 방법 (Sampling)
- 자료의 표현 및 요약 방법
(기술 통계학; descriptive statistics)
- 자료로부터 일반적인 성질을 끄집어 내는 방법
(추론 통계학; inferential statistics)


목차

1. 통계학(Statistics)
2. 모집단과 표본조사 방법
3. 데이터의 종류(Data type)
4. 주요 통계량(Statistic)
5. 다변량 분석(Multivariate Analysis)

Data 분석 과정



- 전수조사(Census)
- 표본조사(Sampling)



모수 (parameter)

- 모집단 평균
- 모집단 분산

모수 (parameter)

- 표본 평균
- 표본 분산 등

Sampling (1/3)

▪ 단순무작위추출법 (simple random sampling)


- 모집단의 모든 대상이 표본으로 선택될 확률이 동일한 추출방법
- 다른 추출법의 기본이 되는 추출법
- 모집단에 대한 사전 정보가 없는 경우 사용
- 난수표 사용
- 실습: 어떤 소비자 단체에서 담배의 니코틴 함유량을 조사하고자 한다. 100개의 모집단에서 임의로 10개의 sample을 단순무작위추출법을 이용해 sampling 해보자

※ Tip) Excel 의 rand() 함수, roundup() 함수 사용

Sampling (2/3)

■ 층화무작위추출법 (stratified random sampling)

- 모집단이 특정 기준에 따라 동질적인 몇 개의 집단으로 분류하고, 각 집단에서 무작위로 표본을 선택하는 방법
- 집단의 특성을 모두 반영해야 하는 경우에 사용
- 집단간의 성격이 이질적이나, 집단 내 대상간의 성격은 동질적이라고 가정
- 실습: 어떤 소비자 단체에서 담배의 니코틴 함유량을 조사하고자 한다. A회사의 담배가 70개, B회사의 담배가 30개가 있다. 10개의 sample을 층화무작위추출법을 이용해 선택해보자



균등 층화,
비례 층화

Sampling (3/3)

- **집락추출법 (cluster sampling)**

- 모집단이 여러 개의 집단으로 구성되어 있는 경우, 전체 집단 중 일부를 무작위로 선택한 뒤, 선택된 집단 모두를 표본으로 조사하는 방법
- 집단간의 차이는 동질적, 집단내의 차이는 이질적이라고 가정함
- 예) 고등학교 학생들의 몸무게 조사

문제 풀이

❖ seaborn의 tips 를 모집단으로 가정하고 3가지 표본추출방법을 파이썬 코드로 제시하라

목차

1. 통계학(Statistics)
2. 모집단과 표본조사 방법
3. 데이터의 종류(Data type)
4. 주요 통계량(Statistic)
5. 다변량 분석(Multivariate Analysis)

통계 Data의 종류

명목형 (nominal)

- 어떤 대상에 숫자나 기호를 부여하여 구분하기 위해 사용
- 크기나 순서가 의미 없음
- 혈액형, 이름

서열형 (ordinal)

- 기준에 따라 대상을 서열화하여 숫자나 기호를 부여
- 순서가 의미 있으나 크기는 의미없음
- 품질등급, 학점, 올림픽 메달

구간형 (interval)

- 대상들간의 상대적인 차이를 비교하는데 사용 (비율은 의미가 없음)
- 온도


비율형 (interval)

- 수치 자체가 실제적인 수량적 의미를 가짐
- 판매량, 무게

목차

1. 통계학(Statistics)
2. 모집단과 표본조사 방법
3. 데이터의 종류(Data type)
4. 주요 통계량(Statistic)
5. 다변량 분석(Multivariate Analysis)

Data 요약 및 표현



Descriptive Statistics: 대표값

▪ 평균 (mean)

- 자료값들의 합(sum)을 표본 크기(관측치의 개수) n 으로 나눈 것, 일반적으로 가장 널리 쓰이는 대표값
- 극단적으로 크거나 작은 값 (outlier) 에 민감
- Ex) 500, 489, 495, 493, 505, 248 $\rightarrow \frac{500 + 489 + 495 + 493 + 505 + 248}{6} = 455$

평균의 함정

▪ 중앙값 (median)

- 자료값들을 크기 순으로 정렬하였을 때 중앙에 위치하는 값, 평균에 비해 극단적으로 크거나 작은 값 (outlier) 에 민감하지 않음
- Ex) 500, 489, 495, 493, 505, 248 $\rightarrow \text{median} = 494$

▪ 최빈값 (mode)

- 자료값들 중 가장 빈도가 많은 자료값

문제 풀이

❖ seaborn의 tip 변수의 값(데이터) 분포, 평균과 분산을 설명하라



❖ 평균의 함정(the pitfall of mean)

❖ seaborn의 tips 모집단에서 3가지 표본추출방법의 각 표본과 모집단과의 평균과 분산을 비교한 후 어떤 표본추출방법이 가장 적합한지 토론하라



<https://www.mt.co.kr/opinion/2019/04/09/2019040811152977932>

문제 풀이


Data Representation

❖ <https://github.com/ancestor9/data/blob/main/customers.csv> 의 데이터를 데이터셋으로 읽은 후
컴퓨터가 인식할 수 있도록 모든 데이터를 수치화하여 표현하라

```
Preview | Code | Blame | 10001 lines (10001 loc) · 641 KB
1  고객 ID,성별,결제수단,거주지,회원등급,만족도,최근접속시간(시),선호제품군_적정온도,나이,구매수량,총결제금액
2  CUST_0001,남성,휴대폰결제,대구,Gold,2,1,27.0,34,7,760355
3  CUST_0002,여성,계좌이체,대구,Gold,5,15,24.6,20,42,727001
4  CUST_0003,여성,신용카드,광주,Gold,1,6,20.3,51,8,618787
5  CUST_0004,여성,계좌이체,서울,VVIP,5,20,16.8,19,29,434545
6  CUST_0005,여성,계좌이체,광주,Gold,3,6,23.5,53,45,604750
7  CUST_0006,기타,계좌이체,경기,Gold,4,22,22.0,22,18,554530
8  CUST_0007,남성,간편결제,광주,VIP,1,3,24.5,41,11,83149
9  CUST_0008,여성,신용카드,대구,VIP,3,10,23.2,70,37,523660
10 CUST_0009,여성,신용카드,대구,Bronze,2,12,25.2,25,36,58966
11 CUST_0010,여성,간편결제,부산,VVIP,2,15,17.3,27,49,792361
12 CUST_0011,기타,휴대폰결제,부산,VVIP,5,16,26.6,54,8,431520
13 CUST_0012,기타,간편결제,서울,Gold,1,22,21.0,64,39,890029
```

	Height	Weight	Income
0	158.1	52.4	380.6
1	142.9	77.1	382.6
2	169.5	17.0	565.3
3	157.4	39.3	324.5
4	178.3	62.0	410.2
...	...	...	...
95	184.5	66.6	401.7
96	170.7	51.5	360.9
97	175.7	100.2	429.9
98	160.0	78.8	374.7
99	159.1	42.9	365.6

100 rows × 3 columns




Descriptive Statistics: 산포 [1/2]

■ 범위 (Range)

- 최대값과 최소값의 차이
- 극단적으로 크거나 작은 값 (outlier) 에 민감
- Ex) 500, 489, 495, 493, 505, 248 → range = 257

■ 사분위 범위 (Inter-quartile range; IQR)

- 사분위수 (quartile): 데이터를 크기순으로 나열하여 4등분 할 경우, 4등분되는 위치에 해당하는 값
 - Q1: 제1사분위수, 25%백분위수 (데이터의 25%에 해당하는 값)
 - Q2: 제2사분위수 (=중앙값), 50%백분위수 (데이터의 50%에 해당하는 값)
 - Q3: 제3사분위수, 75%백분위수 (데이터의 75%에 해당하는 값)
 - Ex) 1,2,3,4,5,6,7,8,9,10
 - Q1 = 3
 - Q2 = 5.5
 - Q3 = 8
- 사분위 범위: Q3-Q1



Descriptive Statistics: 산포 (2/2)

■ 분산 (Variance)

- 각 데이터들이 평균으로 부터 얼마나 떨어져 있는지 표현

$$s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

- Ex) 500, 489, 495, 493, 505, 248

$$s^2 = \frac{(500 - 455)^2 + (489 - 455)^2 + (495 - 455)^2 + (493 - 455)^2 + (505 - 455)^2 + (248 - 455)^2}{5} = 10314.8$$

■ 표준편차 (Standard deviation)

- 분산에 제곱근을 취한 것으로 산포의 척도로 가장 널리 쓰임

- $s = \sqrt{s^2}$

- Ex) 500, 489, 495, 493, 505, 248 $\rightarrow s = 101.6$

Descriptive Illustrations: Histogram (1/4)

- 히스토그램 (Histogram)

- 도수분포표에서 각 구간별 관측도수를 막대형태로 표현한 그래프
- 도수분포표: 전체 data 범위를 구간으로 분할하고, 각 구간에 포함되는 데이터의 도수 (개수)를 산출한 표
- Histogram 작성 순서
 1. 구간 수 결정
 2. 구간 폭 결정 (구간폭 = 범위 / 구간수)
 3. 구간 경계치 결정
 4. 구간별 도수 산출
 5. Histogram 표현

Descriptive Illustrations: Histogram (2/4)


Example) 여대생 신장 자료

170	151	154	160	158	154	171	156	160
157	160	157	148	165	158	159	155	151
152	161	156	164	156	163	174	153	170
149	166	154	166	160	160	161	154	163
164	160	148	162	167	165	158	158	176



1. 구간 수 결정 8
2. 구간 폭 결정 $3.5 (= (176-148)/8)$
3. 구간 경계치 결정 151.5, 155, 158.5, ..., 176
4. 구간별 도수 산출 5, 7, 9, ..., 2
5. Histogram 표현

도수 분포표

구간	도수
151.5	5
155	7
158.5	9
162	10
165.5	6
169	3
172.5	3
176	2
Total	45



여대생 신장의 히스토그램




Source: <http://www.allfortest.co.kr/customer.htm>

- (1) **일반형**: 가장 흔하게 나타나는 분포로 도수가 중심 부근에 가장 많이 분포 되어있어 중심에서 멀어질수록 조금씩 작아진다. 거의 좌우 대칭이다.
- (2) **이빠진형**: 구간을 하나씩 걸러 도수가 작아진 분포의 모양이다. 이가 빠진 모양이 되고 있다. 이런 경우 구간 폭을 눈금의 정수 배로 한다면, 측정자 읽는 법이 제대로 되었는가의 검토가 필요하다.
- (3) **절벽형**(왼쪽, 오른쪽): 평균값이 분포의 중심에서 극단적으로 한쪽에 치우쳐 있다. 이런 경우 측정속임수, 측정오차, 검사미스 등을 체크한다.
- (4) **쌍봉우리형**: 중심부근의 도수가 작아 산의 정상이 좌우로 나누어져 분포되어 있다. 이런 경우는 평균값이 다른 2개의 분포가 섞여 있을 경우에 나타나는데 층별한 히스토그램을 작성해보면 그 차이를 알 수 있다.
- (5) **낙도형**: 히스토그램의 왼쪽 끝이나 오른쪽 끝에 외딴 데이터가 나타난다. 이런 경우 데이터의 이력을 알아 보고 공정에 이상이 없는지, 다른 공정의 데이터가 들어와 있지 않은지 등을 조사한다.
- (6) **고원형**: 각 구간에 포함되어 있는 도수가 별 차이 없는 고원상태가 되고 있다. 이런 경우 층별한 히스토그램을 만들어 비교 검토한다.

Descriptive Illustrations: Box plot (1/2)

■ 상자 그림 (Box plot)

- Data의 분포에 대한 정보를 사분위수를 중심으로 나타내 주는 그림




※ IQR : Inter Quantile Range

Descriptive Illustrations: Box plot (2/2)

- Example) 여대생 신장 자료



170	151	154	160	158	154	171	156	160
157	160	157	148	165	158	159	155	151
152	161	156	164	156	163	174	153	170
149	166	154	166	160	160	161	154	163
164	160	148	162	167	165	158	158	176



문제 풀이

Data Representation

- ❖ 수치형 변수 값의 서로 크기가 다른 경우 scaling하는 방법과 그 이유를 토론하라(Data scaling)
 - ❖ from sklearn.datasets import fetch_california_housing 의 데이터의 변수 중 "MedInc", "AveOccup" 에 대한 joinplot을 시각화하라
 - ❖ https://scikit-learn.org/stable/auto_examples/preprocessing/plot_all_scaling.html 자료원을 이해하고 평균과 분산이 각각 0과 1인 형태로 표준화한 후 시각화 코드를 만들어라



Summary

▪ Sampling 방법

- 단순무작위추출법
- 층화무작위추출법
- 집락추출법

▪ Descriptive statistics

- 대표값: 평균, 중앙값, 최빈값
- 산포: 범위, 사분위범위, 분산, 표준편차
- 왜도, 첨도

▪ Descriptive illustration

- Histogram
- Box plot

기술 통계분석(Descriptive Statistics Analyssis)



- ❖ 모집단으로부터 수집된 데이터를 잘 요약하여 모집단에 대하여 유용한 정보를 생산한다.
- ❖ 기술통계 분석에서는 데이터를 그래프, 표 또는 대표값을 나타내는 숫자(통계량)로 요약한다.
- ❖ 우리는 실생활에서 많은 기술통계 분석 자료를 접할 수 있다.

Descriptive Statistics: 왜도

■ 왜도 (Skewness)

- 자료의 분포에 대한 비대칭의 정도
- 비대칭이 없는 경우 왜도 = 0

$$skewness = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{s} \right)^3$$





- Ex) 500, 489, 495, 493, 505, 248 → $skewness = -2.5$

Descriptive Statistics: 첨도

■ 첨도 (Kurtosis)

- Data 분포의 뾰족한 정도
- 표준정규분포의 경우 첨도 = 0

$$Kurtosis = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{s} \right)^4 - 3$$



- Ex) 500, 489, 495, 493, 505, 248 → $Kurtosis = 5.93$

Descriptive Statistics: 실습

▪ Example) 여대생 신장 자료

170	151	154	160	158	154	171	156	160
157	160	157	148	165	158	159	155	151
152	161	156	164	156	163	174	153	170
149	166	154	166	160	160	161	154	163
164	160	148	162	167	165	158	158	176

- 대표값

- 평균 =
- 중앙값 =

- 산포

- 범위 =
- (Q1, Q2, Q3) =
- 사분위범위 =
- 90%백분위수 =
- (분산, 표준편차) =


- 왜도 =

- 첨도 =

※ Tip) 관련 Excel 함수

: average, median, quartile, percentile, var, stdev, skew, kurt

막대그래프 vs. 히스토그램



구분	막대그래프	히스토그램
데이터 유형	• 범주적 (종교, 직업 등)	• 연속적 (몸무게, 성적 등)
막대 순서	• 임의적으로 변경 가능	• 변경 불가능
막대 간격	• 일정한 간격 유지	• 간격 없이 표현
용도	• 범주의 비교, 순위 표시 등	• 데이터 분포 표현

목차


1. 통계학(Statistics)
2. 모집단과 표본조사 방법
3. 데이터의 종류(Data type)
4. 주요 통계량(Statistic)
5. 다변량 분석(Multivariate Analysis)

상관 분석

산점도

■ 산점도(scatter plot)

- $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 평면좌표에 표시한 도표
- 시각적으로 두 변수의 관계를 쉽게 알 수 있게 해줌
- 변수간 관계의 방향, 형태, 관계의 강도를 알 수 있음



공분산과 표본공분산

■ 공분산(Covariance)

- 두 확률변수 X와 Y의 선형적 상관관계를 측정할 수 있는 척도
- X와 Y가 각각의 평균을 중심으로 하여 같은 방향으로 변화하는 정도를 나타냄
- $\sigma_{xy} = \text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$
- 공분산 값의 크기가 단위 등에 따라 달라짐

■ 표본 공분산 (Sample Covariance)

- σ_{xy} 의 추정량으로 s_{xy} 로 표현

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{1}{n-1} \left(\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y} \right)$$

상관계수와 표본상관계수 [1/3]

■ 상관계수

- 공분산을 단위와 무관하게 표준화시킴
- -1 에서 1까지의 값을 가짐

$$\rho_{XY} = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]}\sqrt{\text{Var}[Y]}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$


■ 표본상관계수

- 상관계수의 추정량으로 r_{xy} 로 표현


$$r_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

상관계수와 표본상관계수 [2/3]


■ 표본상관계수에 따른 산점도




(a) $r = -1$




(b) $r = 1$




(c) $r = -0.7$



(d) $r = 0.5$



(e) $r = 0$



(f) $r = 0$


autodesk

- <https://www.research.autodesk.com/publications/same-stats-different-graphs/>




Anscombe's Quartet

Each dataset has the same summary statistics (mean, standard deviation, correlation), and the datasets are *clearly different*, and *visually distinct*.



Unstructured Quartet

Each dataset here also has the same summary statistics. However, they are not *clearly different* or *visually distinct*.



Appendix 1 : 통계 연습 사이트

❖ Descriptive Statistics

❖ Central Limits Theorem


CS448378

THE STATISTICIAN MARRYING THE
PROBABILITY EXPERT...

You both know
the odds of this
working out...



https://www.cartoonstock.com/directory/s/statistical_probability.asp?srsltid=AfmBOooASIJv72FazaWHEE3MDiL-XPdgl1kKuhjOM1MbHqME4i7P7ulu



<https://pankajr141.wordpress.com/2017/07/29/probability-distributions/>

- ✓ 데이터 분포라는 지도가 있어야, 확률이라는 길을 찾을 수 있다.
- ✓ 데이터 분포와 확률은 뗄 수 없는 “동전의 양면” 같은 관계이다.
- ✓ 데이터의 분포는 “어떤 사건이 일어날 확률의 지도” 라고 할 수 있다.

구분	데이터 분포	확률
관점	과거~현재까지 쌓인 데이터의 모양	미래에 어떤 일이 일어날 가능성
역할	확률을 계산하기 위한 근거 자료	분포를 바탕으로 도출된 결과값